

第2.3节 最小方差无偏估计和有效估计

一、最小方差无偏估计

二、有效估计



一、最小方差无偏估计

最小方差无偏估计在均方误差意义下达到最优，是一种最优估计.如何寻求此种估计，将变得非常有意义.

1 最小方差无偏估计的判别法

定理2.7 设 $\hat{\theta}(X)$ 是 θ 的一个无偏估计， $D(\hat{\theta}) < \infty$ ，若对任何满足条件： $EL(X) = 0, DL(X) < \infty$ 的统计量 $L(X)$ ，有

$$E(L(X)\hat{\theta}(X)) = 0$$



则 $\hat{\theta}(X)$ 是 θ 的 *MVUE*，其中 $X = (X_1, X_2, \dots, X_n)^T$.



证 设 $\hat{\theta}_1(X)$ 是 θ 的一个无偏估计, 令 $L(X) = \hat{\theta}_1(X) - \hat{\theta}(X)$
显然 $EL(X) = E(\hat{\theta}_1(X) - \hat{\theta}(X)) = 0$, 同时
 $D\hat{\theta}_1(X) = D(L(X) + \hat{\theta}(X))$
 $= D[L(X)] + D[\hat{\theta}(X)] + 2E\{[L(X) - EL(X)][\hat{\theta}(X) - E\hat{\theta}(X)]\}$
 $= D[L(X)] + D[\hat{\theta}(X)] \geq D[\hat{\theta}(X)]$
因而, $\hat{\theta}(X)$ 是 θ 的 *MVUE*.

注 1 此定理是最小方差无偏估计的判别法, 但无法寻求最小方差无偏估计的存在性.

2 由于 $L(X)$ 的任意性, 因而很难利用定理判别.



例1 (p54例2. 20) 设 $X = (X_1, X_2, \dots, X_n)^T$ 是来自总体 $N(\mu, \sigma^2)$ 的一个样本, 已知 \bar{X} 和 S_n^{*2} 是 μ 和 σ^2 的无偏估计, 证明 \bar{X} 和 S_n^{*2} 分别是 μ 和 σ^2 的 *MVUE*.


证 设 $L(X)$ 满足 $EL(X) = 0$, 则

$$\int \cdots \int L \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} d\mathbf{x} = 0$$

两边关于 μ 求导, 则

$$\int \cdots \int L \cdot \sum_{i=1}^n x_i \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} d\mathbf{x} = 0$$

因而 $E(L(X)\bar{X}) = 0$



故 \bar{X} 是 μ 的MVUE.

对此式 $\int \cdots \int L \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} d\mathbf{x} = 0$ 关于 μ

求二阶导数, 则

$$\int \cdots \int L \cdot \left(\sum_{i=1}^n x_i\right)^2 \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} d\mathbf{x} = 0$$

对此式 $\int \cdots \int L \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} d\mathbf{x} = 0$ 关于 σ^2

求导数, 则

$$\int \cdots \int L \cdot \sum_{i=1}^n (x_i - \mu)^2 \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} d\mathbf{x} = 0$$



又由于 $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \mu)^2 - n(\bar{x} - \mu)^2$, 可得

$$\int \cdots \int L \cdot \sum_{i=1}^n (x_i - \bar{x})^2 \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} d\mathbf{x} = 0$$

因而 $E(L(X)S_n^{*2}) = 0$

故 S_n^{*2} 是 σ^2 的 *MVUE*.

由此例可以看出, 利用判别定理进行判别, 非常复杂, 况且也无法利用此定理去寻求 *MVUE*.

充分完备统计量是解决上述困难的有力工具.



定理2.8 设总体 X 的分布函数为 $F(x, \theta)$, $\theta \in \Theta$ 是未知参数, $X = (X_1, X_2, \dots, X_n)^T$ 是来自总体 X 的一个样本, 如果 $T = T(X_1, X_2, \dots, X_n)$ 是 θ 的充分统计量, $\hat{\theta}$ 是 θ 的任一无偏估计, 记 $\hat{\theta}^* \stackrel{\Delta}{=} E(\hat{\theta} | T)$

则有

$$E\hat{\theta}^* = \theta, \quad \theta \in \Theta,$$
$$D\hat{\theta}^* \leq D\hat{\theta}, \quad \theta \in \Theta,$$

即 $\hat{\theta}^*$ 是 θ 的MVUE.

证明从略



由于 $\hat{\theta}^* = E(\hat{\theta} | T)$ 仍然是充分统计量且作为 θ 的估计量，可称之为充分估计量，上述定理表明，要寻找 θ 的最小方差无偏估计，只需在无偏的充分估计量类中寻找就足够了。假若 θ 的充分无偏估计量是唯一的，则这个充分无偏估计量一定是最小方差无偏估计量，那么在什么情况下，它才是唯一的呢？显然，如果它又是完备统计量，便可保证其唯一性。



定理2.9 设总体 X 的分布函数为 $F(x, \theta)$, $\theta \in \Theta$ 是未知参数, $X = (X_1, X_2, \dots, X_n)^T$ 是来自总体 X 的一个样本, 如果 $T = T(X_1, X_2, \dots, X_n)$ 是 θ 的充分完备统计量, $\hat{\theta}$ 是 θ 的任一无偏估计, 记 $\hat{\theta}^* \triangleq E(\hat{\theta} | T)$ 则 $\hat{\theta}^*$ 是 θ 的唯一的 $MVUE$.



证 设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 是 θ 的任意两个无偏估计, T 是充分统计量, 由定理2.8可知

$$E_{\theta}[E(\hat{\theta}_1 | T)] = E\hat{\theta}_1 = \theta, \quad E_{\theta}[E(\hat{\theta}_2 | T)] = E\hat{\theta}_2 = \theta \quad (*)$$

以及

$$D_{\theta}[E(\hat{\theta}_1 | T)] \leq D\hat{\theta}_1, \quad D_{\theta}[E(\hat{\theta}_2 | T)] \leq D\hat{\theta}_2$$

由此(*)式可得 $E_{\theta}[E(\hat{\theta}_1 | T) - E(\hat{\theta}_2 | T)] = 0$

又 T 是完备统计量, 由完备统计量定义可知

$$P\{E(\hat{\theta}_1 | T) = E(\hat{\theta}_2 | T)\} = 1$$

即 θ 的充分无偏估计唯一, 由定理2.8可知 $\hat{\theta}^* = E(\hat{\theta}_1 | T)$ 是 *MVUE*.




注 最小方差无偏估计计算方法

- 1、构造一个充分完备统计量 $T(X_1, \dots, X_n)$ 和一个 θ 的无偏估计 $\hat{\theta}$.
- 2、计算 $E(\hat{\theta} | T)$, 即得 θ 的一个 *MVUE*.

例如

\bar{X} 是泊松分布 λ 的充分完备统计量, 同时也是 λ 的无偏估计, 则 $E(\bar{X} | \bar{X}) = \bar{X}$ 是 λ 的一个 *MVUE*.



例2 (p56例2. 21) 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 为未知参数, $(X_1, X_2, \dots, X_n)^T$ 是来自 X 的一个样本, 求 μ 和 σ^2 的最小方差无偏估计量.

解 由例1.10可知

$T = (\bar{X}, S_n^2)$ 是 (μ, σ^2) 的充分完备统计量, 因而

$$\hat{\mu} = E(\bar{X} | T) = \bar{X}, \quad \hat{\sigma}^2 = E(S_n^{*2} | T) = S_n^{*2}$$

所以

\bar{X} 和 S_n^{*2} 分别是 μ 和 σ^2 的最小方差无偏估计量.



例3(p56例2.22) 设总体 X 在 $[0, \theta]$ 上服从均匀分布, 其中 $\theta (\theta > 0)$ 未知, $(X_1, X_2, \dots, X_n)^T$ 是来自总体 X 的样本, 求 θ 的最小方差无偏估计量.

解 首先寻求充分完备统计量, 样本的联合分布为

$$L(\theta) = \prod_{i=1}^n f(x_i) = \begin{cases} \frac{1}{\theta^n}, & 0 < x_{(1)} < \dots < x_{(n)} < \theta \\ 0, & \text{其他} \end{cases}$$
$$= \theta^{-n} I_{(0, \theta)}(x_{(n)})$$

其中 $I_{(0, \theta)}(x) = 1$ 当 $0 < x < \theta$.



由因子分解定理, $X_{(n)}$ 是 θ 的充分统计量, 其分布密度为

$$f_{X_{(n)}}(x) = \begin{cases} \frac{n}{\theta^n} x^{n-1} & 0 < x < \theta \\ 0 & \text{其他} \end{cases}$$

利用完备分布族定义可以验证该分布族具有完备性.

又由于 $E(X_{(n)}) = \int_0^\theta \frac{n}{\theta^n} x^n dx = \frac{n}{n+1} \theta$

$$E\left(\frac{n+1}{n} X_{(n)}\right) = \theta$$

所以 $E\left(\frac{n+1}{n} X_{(n)} \mid X_{(n)}\right) = \frac{n+1}{n} X_{(n)}$ 是 θ 的 *MVUE*.



二、有效估计

上一节介绍了最小方差无偏估计以及相应的寻求方法。自然会引入另一个问题：无偏估计的方差是否可以任意的小？是否有下界？事实上，**Rao-Cramer不等式**可以回答此问题。

1、Fisher信息量

设总体 X 的分布密度为 $f(x, \theta)$, $X = (X_1, X_2, \dots, X_n)^T$ 为其样本，则称

$$I(\theta) = E\left(\frac{\partial \ln f(X; \theta)}{\partial \theta}\right)^2$$

为Fisher信息量.



Fisher信息量的另外一种表达式为:

$$I(\theta) = -E\left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2}\right]$$

2、Rao-Cramer不等式

定理2.10 设 Θ 是实数轴上的一个开区间, 总体 X 的分布密度为 $f(x; \theta)$, $\theta \in \Theta$, $(X_1, X_2, \dots, X_n)^T$ 是来自总体 X 的一个样本, $T = T(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的一个无偏估计量, 且满足条件:

(1) 集合 $S = \{x \mid f(x; \theta) \neq 0\}$ 与 θ 无关;



(2) $\frac{\partial f(x; \theta)}{\partial \theta}$ 存在且对 Θ 中一切 θ 有

$$\frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} f(x; \theta) dx = \int_{-\infty}^{+\infty} \frac{\partial f(x; \theta)}{\partial \theta} dx,$$

$$\begin{aligned} & \frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, x_2, \cdots, x_n) L(x, \theta) dx_1 dx_2 \cdots dx_n \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, x_2, \cdots, x_n) \frac{\partial}{\partial \theta} L(x, \theta) dx_1 dx_2 \cdots dx_n \end{aligned}$$

其中 $L(x, \theta) = \prod_{i=1}^n f(x_i; \theta);$



$$(3) \quad I(\theta) = E\left(\frac{\partial \ln f(X; \theta)}{\partial \theta}\right)^2 > 0$$

则对一切 $\theta \in \Theta$, 有 $D(T(X)) \geq \frac{(g'(\theta))^2}{nI(\theta)}$, 其中

$\frac{(g'(\theta))^2}{nI(\theta)}$ 为罗-克拉美下界, $I(\theta)$ 称为 *Fisher* 信息量。

特别是当 $g(\theta) = \theta$ 时, 有 $D(T(X)) \geq \frac{1}{nI(\theta)}$.

由此可见, 统计量的方差不可以无限的小, 存在下界。当无偏估计的方差达到下界, 它一定是MVUE。但最小方差无偏估计不一定达到下界。



证

由统计量 $T(X)$ 的无偏性可知:

$$ET(X) = \int T(x)L(x, \theta)dx = g(\theta)$$

因而

$$\int T(x) \frac{\partial L(x, \theta)}{\partial \theta} dx = g'(\theta)$$

又由于 $\int L(x, \theta)dx = 1$

因而 $\int \frac{\partial L(x, \theta)}{\partial \theta} dx = 0$

则有 $\int (T(x) - g(\theta)) \frac{\partial L(x, \theta)}{\partial \theta} dx = g'(\theta)$



改写上式为

$$g'(\theta) = \int \{(T(x) - g(\theta))\sqrt{L(x, \theta)}\} \left\{ \frac{\sqrt{L(x, \theta)}}{L(x, \theta)} \frac{\partial L(x, \theta)}{\partial \theta} \right\} dx$$

由施瓦兹不等式可知

$$(g'(\theta))^2 \leq \int \{(T(x) - g(\theta))^2 L(x, \theta) dx$$

$$\times \int \frac{1}{L(x, \theta)} \left(\frac{\partial L(x, \theta)}{\partial \theta} \right)^2 dx$$

$$= D(T(X)) \times \int \frac{1}{L(x, \theta)} \left(\frac{\partial L(x, \theta)}{\partial \theta} \right)^2 dx$$

$$= D(T(X)) \times \int \left(\frac{\partial \ln L(x, \theta)}{\partial \theta} \right)^2 L(x, \theta) dx$$



$$= D(T(X)) \times E\left(\frac{\partial \ln L(x, \theta)}{\partial \theta}\right)^2$$

因而有

$$D(T(X)) \geq \frac{(g'(\theta))^2}{E\left(\frac{\partial \ln L(x, \theta)}{\partial \theta}\right)^2}$$

又因为

$$\begin{aligned} E\left(\frac{\partial \ln L(x, \theta)}{\partial \theta}\right)^2 &= \sum_{i=1}^n \sum_{j=1}^n E\left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right) \left(\frac{\partial \ln f(x_j, \theta)}{\partial \theta}\right) \\ &= \sum_{i=1}^n E\left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right)^2 = \sum_{i=1}^n E\left(\frac{\partial \ln f(x, \theta)}{\partial \theta}\right)^2 \end{aligned}$$

这是因为



$$\begin{aligned}
 \text{当 } i \neq j \text{ 时, } & E\left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right) \left(\frac{\partial \ln f(x_j, \theta)}{\partial \theta}\right) \\
 &= E\left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right) E\left(\frac{\partial \ln f(x_j, \theta)}{\partial \theta}\right) \\
 &= E\left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right) \int \frac{\partial \ln f(x_j, \theta)}{\partial \theta} f(x_j, \theta) dx_j \\
 &= E\left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right) \int \frac{\partial f(x_j, \theta)}{\partial \theta} dx_j = 0
 \end{aligned}$$

则有

$$E\left(\frac{\partial \ln L(x, \theta)}{\partial \theta}\right)^2 = \sum_{i=1}^n E\left(\frac{\partial \ln f(x, \theta)}{\partial \theta}\right)^2 = nI(\theta)$$

综上所述

$$D(T(X)) \geq \frac{(g'(\theta))^2}{nI(\theta)}$$



例4(p58例2.23) 设 $(X_1, X_2, \dots, X_n)^T$ 是来自泊松分布 $P(\lambda)$ 的一个样本, 试求 λ 的无偏估计的方差下界。

解 由于 $f(x; \lambda) = \frac{\lambda^x}{x!} e^{-\lambda}$, $E(\bar{X}) = \lambda$, $D(\bar{X}) = \frac{\lambda}{n}$,

则
$$I(\lambda) = E\left[\frac{\partial \ln f(X, \lambda)}{\partial \lambda}\right]^2 = E\left(\frac{\partial (X \ln \lambda - \lambda - \ln X!)}{\partial \lambda}\right)^2$$

$$= E\left(\frac{X}{\lambda} - 1\right)^2 = \frac{1}{\lambda^2} E(X - \lambda)^2 = \frac{1}{\lambda^2} D(X) = \frac{1}{\lambda}$$

因此
$$D(\hat{\lambda}) \geq \frac{1}{nI(\lambda)} = \frac{\lambda}{n}$$

所以 \bar{X} 是 λ 的最小方差无偏估计。



例5(p58例2.24) 设 $(X_1, X_2, \dots, X_n)^T$ 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, 试求 μ 和 σ^2 的无偏估计的方差下界.

解
$$\ln f(x, \mu, \sigma^2) = -\ln \sqrt{2\pi} - \frac{1}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (x - \mu)^2$$

$$I(\mu) = E\left\{\frac{\partial \ln f(X, \mu, \sigma^2)}{\partial \mu}\right\}^2 = E \frac{(X - \mu)^2}{\sigma^4} = \frac{1}{\sigma^2}$$

其罗克拉美的下界为
$$\frac{1}{nI(\mu)} = \frac{\sigma^2}{n} = D(\bar{X})$$

所以样本均值 \bar{X} 为 μ 的最小方差无偏估计.



又因为

$$\frac{\partial \ln f(x, \mu, \sigma^2)}{\partial \sigma^2} = -\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2\sigma^4}$$

$$\frac{\partial^2 \ln f(x, \mu, \sigma^2)}{\partial (\sigma^2)^2} = \frac{1}{2\sigma^4} - \frac{(x - \mu)^2}{\sigma^6}$$

$$I(\sigma^2) = -E\left\{\frac{\partial^2 \ln f(X, \mu, \sigma^2)}{\partial (\sigma^2)^2}\right\} = \frac{E(X - \mu)^2}{\sigma^6} - \frac{1}{2\sigma^4} = \frac{1}{2\sigma^4}$$

其罗克拉美的下界为 $\frac{1}{nI(\sigma^2)} = \frac{2\sigma^4}{n} < D(S_n^{*2}) = \frac{2\sigma^4}{n-1}$

这是因为 $D\left(\frac{(n-1)S_n^{*2}}{\sigma^2}\right) = 2(n-1)$, 因而 $D(S_n^{*2}) = \frac{2\sigma^4}{n-1}$.



即 S_n^{*2} 的方差达不到罗-克拉美下界。但是由例2.20知, S_n^{*2} 是 σ^2 的最小方差无偏估计, 这表明最小方差无偏估计量的方差不一定能够达到罗-克拉美下界。为此, 引入有效估计的概念。



3、有效估计

定义2.8 设 $\hat{\theta}$ (或 $T(X)$)是 θ (或 $g(\theta)$)的一个无偏估计, 若

$$D(\hat{\theta}) = \frac{1}{nI(\theta)} \text{ (或 } D(T(X)) = \frac{[g'(\theta)]^2}{nI(\theta)} \text{)}$$

则称 $\hat{\theta}$ (或 $T(X)$)是 θ (或 $g(\theta)$)的有效估计

定义2.9 设 $\hat{\theta}$ 是 θ 的任一无偏估计, 称 $e(\hat{\theta}) = \frac{(1/nI(\theta))}{D(\hat{\theta})}$

为估计量 $\hat{\theta}$ 的效率。显然 $0 < e(\hat{\theta}) \leq 1$.

定义2.10 如果 θ 的无偏估计量 $\hat{\theta}$ 的效率满足 $\lim_{n \rightarrow \infty} e(\hat{\theta}) = 1$

则称 $\hat{\theta}$ 为 θ 的渐近有效估计(量)。



如果 $\hat{\theta}$ 是 θ 的有效估计, 则它也是最小方差无偏估计。但反之却不成立。

例6 设 $(X_1, X_2, \dots, X_n)^T$ 是来自 $N(\mu, \sigma^2)$ 的一个样本, 证明: \bar{X} 是 μ 的有效估计量; S_n^{*2} 是 σ^2 的渐近有效估计量。

证 由信息量计算公式可知:

$$\begin{aligned} I(\mu) &= E\left(\frac{\partial \ln f(X, \mu, \sigma^2)}{\partial \mu}\right)^2 = E\left(\frac{X - \mu}{\sigma^2}\right)^2 \\ &= \frac{1}{\sigma^2} \end{aligned}$$



$$e(\bar{X}) = \frac{1/(nI(\mu))}{D(\bar{X})} = \frac{\sigma^2/n}{\sigma^2/n} = 1$$

$$I(\sigma^2) = -E\left\{\frac{\partial^2 \ln f(X, \mu, \sigma^2)}{\partial(\sigma^2)^2}\right\} = \frac{E(X - \mu)^2}{\sigma^6} - \frac{1}{2\sigma^4} = \frac{1}{2\sigma^4}$$

$$D\left(\frac{(n-1)S_n^{*2}}{\sigma^2}\right) = 2(n-1), \quad \text{因此 } D(S_n^{*2}) = \frac{2\sigma^4}{n-1}$$

$$\text{所以 } e(S_n^{*2}) = \frac{1/nI(\sigma^2)}{D(S_n^{*2})} = \frac{n-1}{n} \rightarrow 1$$



例7 (p60例2. 25) 设 $X \sim B(N, p)$, X_1, X_2, \dots, X_n 为总体

X 的一个样本, 试证 $\hat{p} = \frac{1}{N} \bar{X}$ 是 p 的有效估计量。

$$\begin{aligned} \text{证 } I(p) &= E\left(\frac{\partial \ln f(X, p)}{\partial p}\right)^2 \\ &= E\left[\frac{d[\ln C_N^X + X \ln p + (N - X) \ln(1 - p)]}{dp}\right]^2 \\ &= E\left(\frac{X}{p} - \frac{N - X}{1 - p}\right)^2 = \frac{1}{p^2(1 - p)^2} E(X - Np)^2 \\ &= \frac{Np(1 - p)}{p^2(1 - p)^2} = \frac{N}{p(1 - p)} \end{aligned}$$

$$D(\hat{p}) = \frac{D(\bar{X})}{N^2} = \frac{p(1 - p)}{Nn} \quad e(\hat{p}) = \frac{1/(nI(p))}{D(\hat{p})} = 1$$



定理2.11 设总体 X 的分布函数为 $F(x, \theta)$, $\theta \in \Theta$ 是未知参数, $X = (X_1, X_2, \dots, X_n)^T$ 是来自总体 X 的一个样本, 如果 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的无偏估计量, 则 $\hat{\theta}$ 是 θ 的有效估计的充分必要条件为:

1、 $\hat{\theta}$ 是 θ 的充分估计量;

$$2、\frac{\partial \ln L(x, \theta)}{\partial \theta} = C(\theta)[\hat{\theta}(x_1, x_2, \dots, x_n) - \theta]$$

其中 $L(x, \theta)$ 是样本的联合分布密度, $C(\theta)$ 仅依赖参数 θ .

证明从略。



例8 (p61例2. 26) 设 X 服从两点分布 $B(1, p)$, X_1, X_2, \dots, X_n 是来自 X 的一个样本, 证明 p 的最大似然估计量是有效估计.

解 因为 X 的分布律为

$$P\{X = x\} = p^x (1 - p)^{1-x} \quad (x = 0, 1)$$

所以 p 的似然函数为

$$L(p) = \prod_{i=1}^n \left(p^{x_i} (1 - p)^{1-x_i} \right) = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}$$



$$\ln L(p) = \left(\sum_{i=1}^n x_i \right) \ln p + \left(n - \sum_{i=1}^n x_i \right) \ln(1-p),$$

$$\frac{d}{dp} \ln L(p) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = \frac{n}{p(1-p)} (\bar{x} - p) = 0$$

解得 p 的最大似然估计值 $\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$,

又因为 $\frac{\partial \ln L(x, p)}{\partial p} = C(p)[\hat{p}(x_1, x_2, \dots, x_n) - p]$, 其中

$C(p) = \frac{n}{p(1-p)}$, 同时 \bar{X} 是 p 的充分统计量, 因而由

定理2.11可知, \bar{X} 是 p 的有效估计.



Thank You!

